[Oxalate]

Проект №146 Разпределени приложения

1. Тема: Интелигентна система за оптимизиране на търсенето в Интернет

2. Автори:

Участник 1 **Симеон Николаев Вангелов**

ЕГН : 0841250445

Адрес : гр. Бургас, кв. Банево, ул. Тракия 6

Тел : 0988903144

Имейл : simmeon.nv@proton.me

ППМГ „Акад. Никола Обрешков“ Бургас, 11 клас

Участник 2 **Любомир Христов Иванов**

ЕГН : 0846230462

Адрес : гр. Бургас, ул. "Сливница", № 31

Тел : 09885556450

Имейл : bvvn@protonmail.com

ППМГ „Акад. Никола Обрешков“ Бургас, 11 клас

3. Ръководител:

Д-р Александър Иванов

0988378335, alex.milagro@abv.bg

Старши учител в ППМГ „Акад. Никола Обрешков“ Бургас

4. Резюме

4.1. Цели:

Глобалната цел на проекта е да предостави сигурна и иновативна платформа за откриване на информация в интернет, която стриктно приоритизира безопасността и анонимността на потребителите. Системата е проектирана да функционира, както като напълно самостоятелна търсачка, така и като мета-търсачка, която агрегира и оптимизира резултати от други търсещи машини. Уникална черта на проекта е предоставянето на сложни и интерактивни графови визуализации на заявките за търсене, което позволява на потребителите да изследват и осмислят връзките между различните данни по един изцяло нов, визуален начин.

Наличните функционалности, които ще се поддържат, са:

- Самостоятелно търсене на информация със собствено индексиране
- Мета-търсене, обединяващо и филтриращо резултати от външни търсачки
- Генериране на интерактивни графови визуализации въз основа на потребителската заявка
- Осигуряване на пълна анонимност на потребителя (без проследяване и запазване на лични данни)

По време на разработка на проекта се използва платформата Github, която е Git система за контрол и управление на версиите.

Програмният код на проекта е достъпен на следните адреси:

Главният код: https://github.com/simeonnv/Oxalate

Api gateway: https://github.com/simeonnv/Servo

Кодът на проекта е лицензиран под GNU General Public License v3.0

Приложението е достъпно на следния адрес: https://oxalate.ate6.org/

4.2.Основни етапи в реализирането:

- Анализ на различните технологии за реализация на проекта
- Планиране на архитектурата
- Програмна реализация
- Тестване на основните функционалности
- Преработка и отстраняване на бъгове

- Имплементация и визуализация на резултати
- Тестове и анализи

При реализирането на проекта задачите между авторите са разпределени съобразно техните интереси и компетентности.

Симеон Вангелов участва активно в проектирането и разработката на backend архитектурата на системата, както и в изграждането на потребителския интерфейс.

Любомир Иванов е ангажиран основно с разработката и усъвършенстването на потребителския интерфейс, като допринася за функционалността и визуалната достъпност на приложението.

4.3. Ниво на сложност на проекта:

Проектът се характеризира с високо ниво на сложност, обусловено от съчетанието на архитектурни, алгоритмични и технологични предизвикателства, както и от необходимостта за осигуряване на висока производителност, сигурност и мащабируемост.

Една от основните трудности при реализацията е проектирането и синхронизирането на разпределена микросервисна архитектура, в която отделните компоненти функционират самостоятелно, но трябва да обменят данни надеждно и ефективно. Това изисква внимателно планиране на интерфейсите между услугите, обработката на грешки и контрола на достъпа.

Съществен проблем представлява и обработката на големи обеми от данни в реално време, включително асинхронен и паралелен уеб скрейпинг, индексиране и търсене. За решаването му са използвани неблокиращи структури от данни и конкурентни алгоритми, с цел предотвратяване на блокиране на системата и загуба на производителност.

Допълнителна сложност произтича от използването на различни типове бази данни, всяка с различен модел на съхранение и предназначение – релационна, графова, кешираща и търсеща. Това налага синхронизиране на данните между тях и оптимизиране на заявките според спецификата на всяка база.

4.4.Логическо и функционално описание на решението:

Системата предлага следния набор от функции за крайните потребители и администраторите:

- Търсене и филтриране: Възможност за извършване на комплексни заявки с висока скорост и точност.
- Интерактивна граф визуализация: Потребителският интерфейс предоставя динамично платно (canvas), където резултатите са представени като свързани възли. Потребителите могат да взаимодействат с графа (мащабиране, местене, кликване върху възли за детайли).
- Мета-търсене: Интеграция с външни търсачки с цел обединяване на резултати от различни платформи в единен визуален формат.
- Административен панел (admin _ui): За управления на скрейпинг механизма.

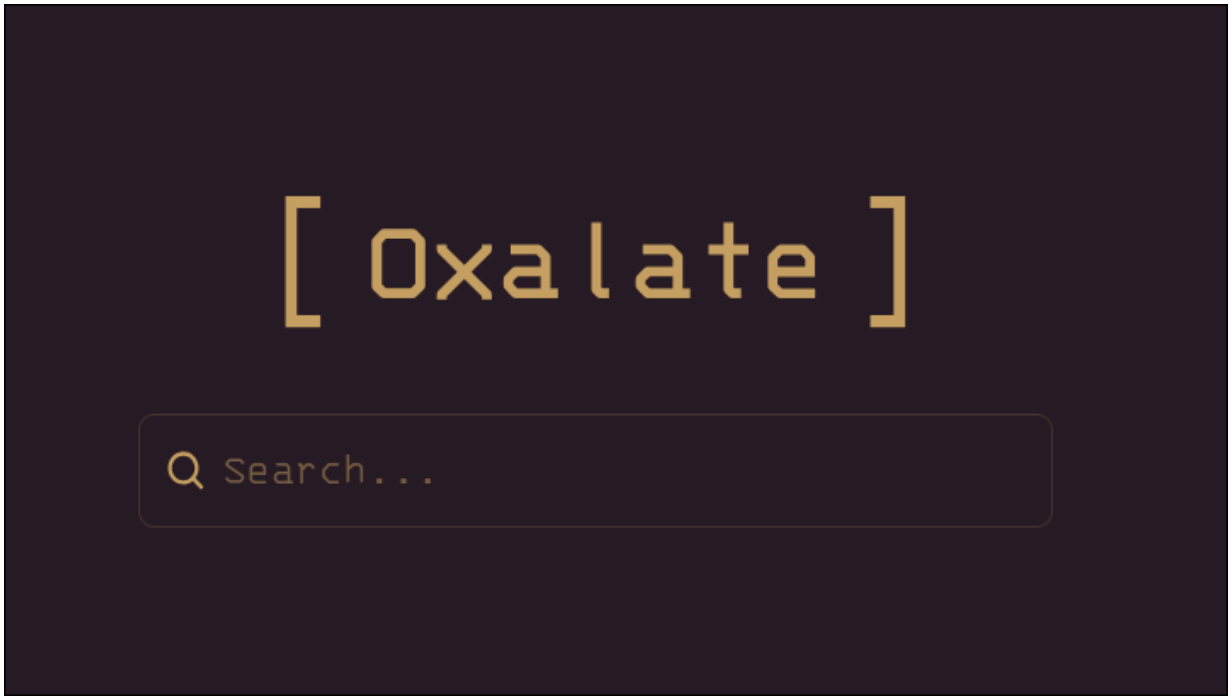

Фигура 1 Основен интерфейс

4.5.Реализация:

4.5.1. Обща архитектура

При реализацията на проекта са използвани съвременни технологии, съобразени с изискванията за висока производителност, мащабируемост и сигурност

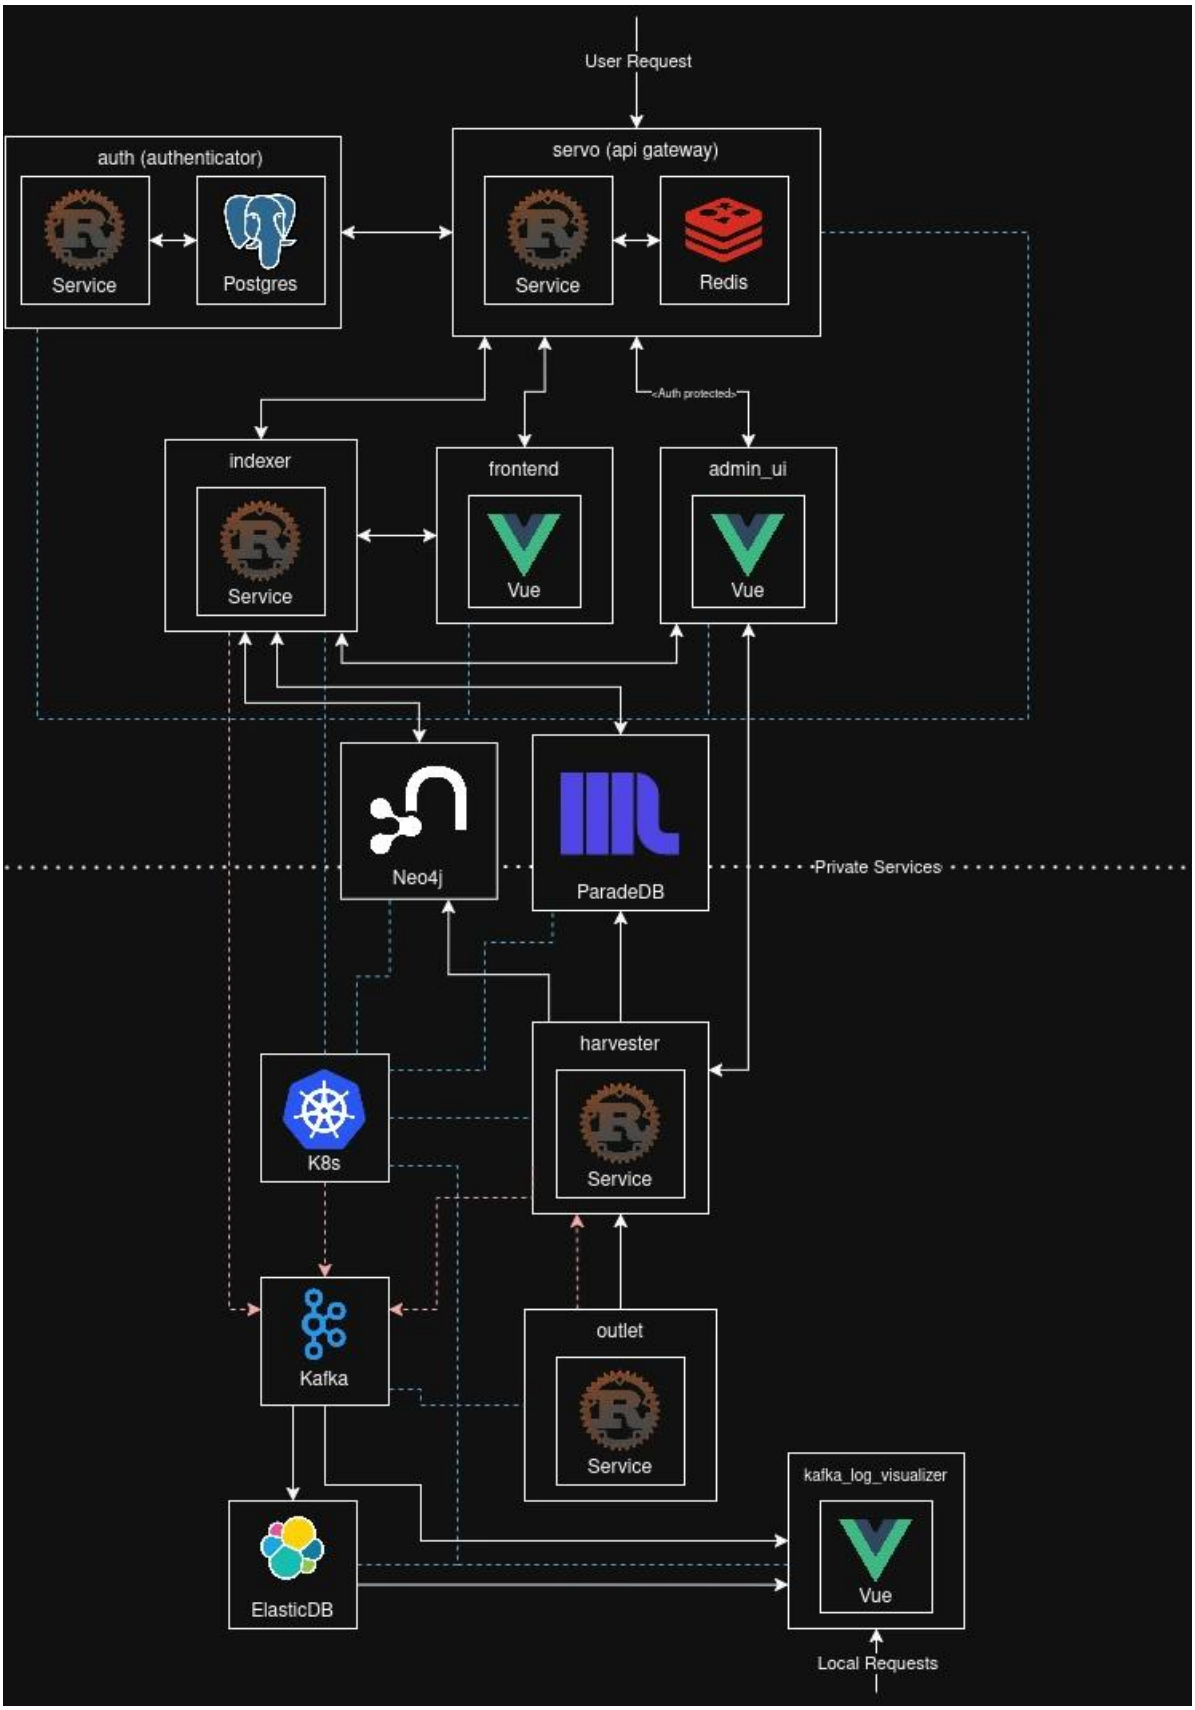

Фигура 2 Обща архитектура

4.5.2. Избор на технологични средства

4.5.2.1.Програмни езици

- Rust - използван за backend компонентите поради високата си производителност, безопасност на паметта и добри възможности за паралелна обработка.
- Typescript - използван за frontend частта с цел по-добра типова сигурност и поддържаемост на кода.
- Nix - използван за автоматизиране на средата за разработка и изграждане на Docker изображения.

4.5.2.2.Фреймуъркове и библиотеки

- NuxtJS – за разработка на frontend интерфейса.
- Axum – backend framework за Rust, ориентиран към изграждане на REST API.
- Utoipa и Swagger – за автоматично генериране на API документация.

4.5.3. Бази данни

- Redis - използва се като бърз кеш за често достъпвани страници.
- Postgres - основна релационна база данни с разширени възможности за пълнотекстово търсене и алгоритъм BM25 за класиране на резултатите.
- Neo4j - графова база данни, използвана за съхраняване и визуализиране на релациите между думи и страници.
- Elastic Search - използва се за оптимизирано търсене и обработка на телеметрични данни.

4.5.4. Инструменти за деплоймент

- Docker - емулация на вируални машини
- Kubernetes - оркестратор за Docker инстанции

4.5.5. Архитектура и микросервиси

Проектът е реализиран като разпределена микросервисна система. Основните компоненти са:

○ **servo** - обратен прокси сървър, който играе ролата на “API gateway”. Всички заявки минават през него. Той осигурява авторизацията на потребителя и забързва заявките, като връща предварително подготвени заявки от кеша (Redis).

○ **servo_auth** - авторизатор. Енкапсулира криптографичните подписни ключове нужни за създаването на нови refresh токени и session токени.

○ **oxalate_harvester** - оркестратор за oxalate_outlet инстанциите. Обработва страници и ги запазва в базите от данни.

○ **oxalate_outlet** - отговаря за скрейпването на страници. Праща всички заявки към oxalate_harvester за обработка.

○ **oxalate_indexer** – използва се за обработката към заявката за търсене на потребителя и съответно индексира информацията от базите от данни.

○ **frontend** – потребителски интерфейс.

○ **admin_ui** – административен интерфейс.

○ **kafka_log_visualizer** – интефейс за debugging. От него е възможен достъп и филтрация на всички логове в реално време.

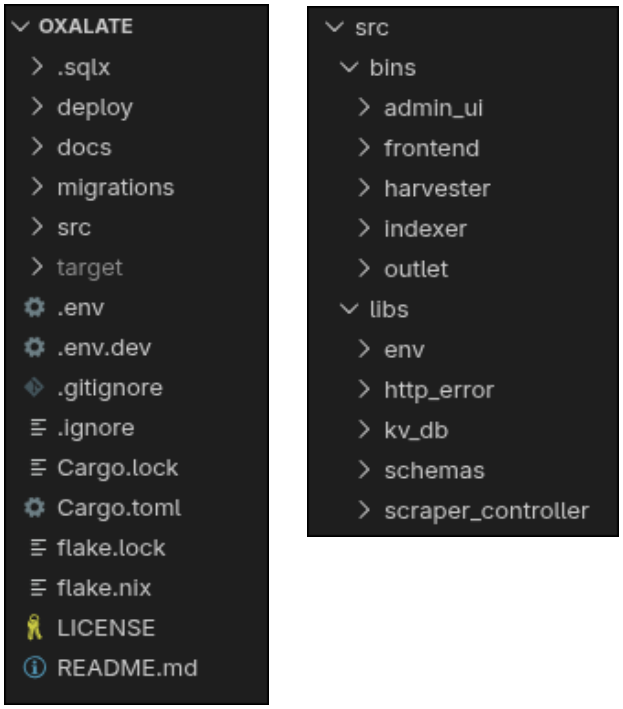

Фигура 3 Файлова структура на проекта

4.5.6. Организация на файловете

Файловете flake.nix и flake.lock са позиционирани е главната папка. Те се ползват за създаване средата за програмиране, нужна за работа по кода.

В папката migrations/ са разположени всички SQL заявки за инстанциране на таблиците от Postgres базата данни.

В папката deploy/ е кодът за деплойване.

Документацията на проекта е позиционирана в папката в docs.

И накрая в src е разположен главният код.

4.5.7. Подредба на кода в бизнес логиката

- src/ папката е разделена на 2 части:
  - bins/, където е разположен кодът на всеки микросервис.
  - libs/ , съдържаща споделения код на всички микросервиси.
- libs/env съдържа кода, отговарящ за четенето и десериализирането на env variables.
- libs/http_error съдържа структура от данни, която е маркиран съюз (tagged union), който се ползва за представянето на всички типове HTTP кодови грешки.
- libs/kv_db съдържа код за система за запазване и синхронизиране на програмното състояние (state).-
- libs/schemas е предназначена за дефиниции на структурите за заявки (Req) и отговори (Res) на всички API endpoints на всички сервиси
- libs/scraper_controller съдържа системата за генериране и оркестриране на задачи за скреиперите.

4.5.8. Дизайн на кода

- Стил на програмиране

Кодът е изграден върху функционален и императивен стил, целящ предвидимост и висока производителност. Цялото състояние (state) на приложението е централизирано и "закачено" на едно място, което гарантира валидността на данните и улеснява проследяването на логиката.

- Модела на паралелизма

Кодът силно разчита на неблокиращи структури от данни (Non-blocking Async Data Structures), за да предотврати блокирането на програмата при четене на състоянието. Пример за неблокираща структура от данни е lock sharded hashmap имплементиран в rust като библиотеката “dashmap”. Също има силна употреба на атомарни променливи, за да предотврати надпревара на нишките (Race condition).

За сигурно споделяне на структури от данни между различните нишки (threads) се използват атомарни указатели с брояч на референциите (Atomic Reference Counted Pointers) (ARC Pointers).

- Web архитектурен стил.

Проектът е написан със стила REST API, като се ползват JSON символни низове за сериализиране на структури от данни за предаване по мрежата. Ползвани са библиотеките utoipa и swagger за генериране на REST API документация.

4.5.9. Авторизация

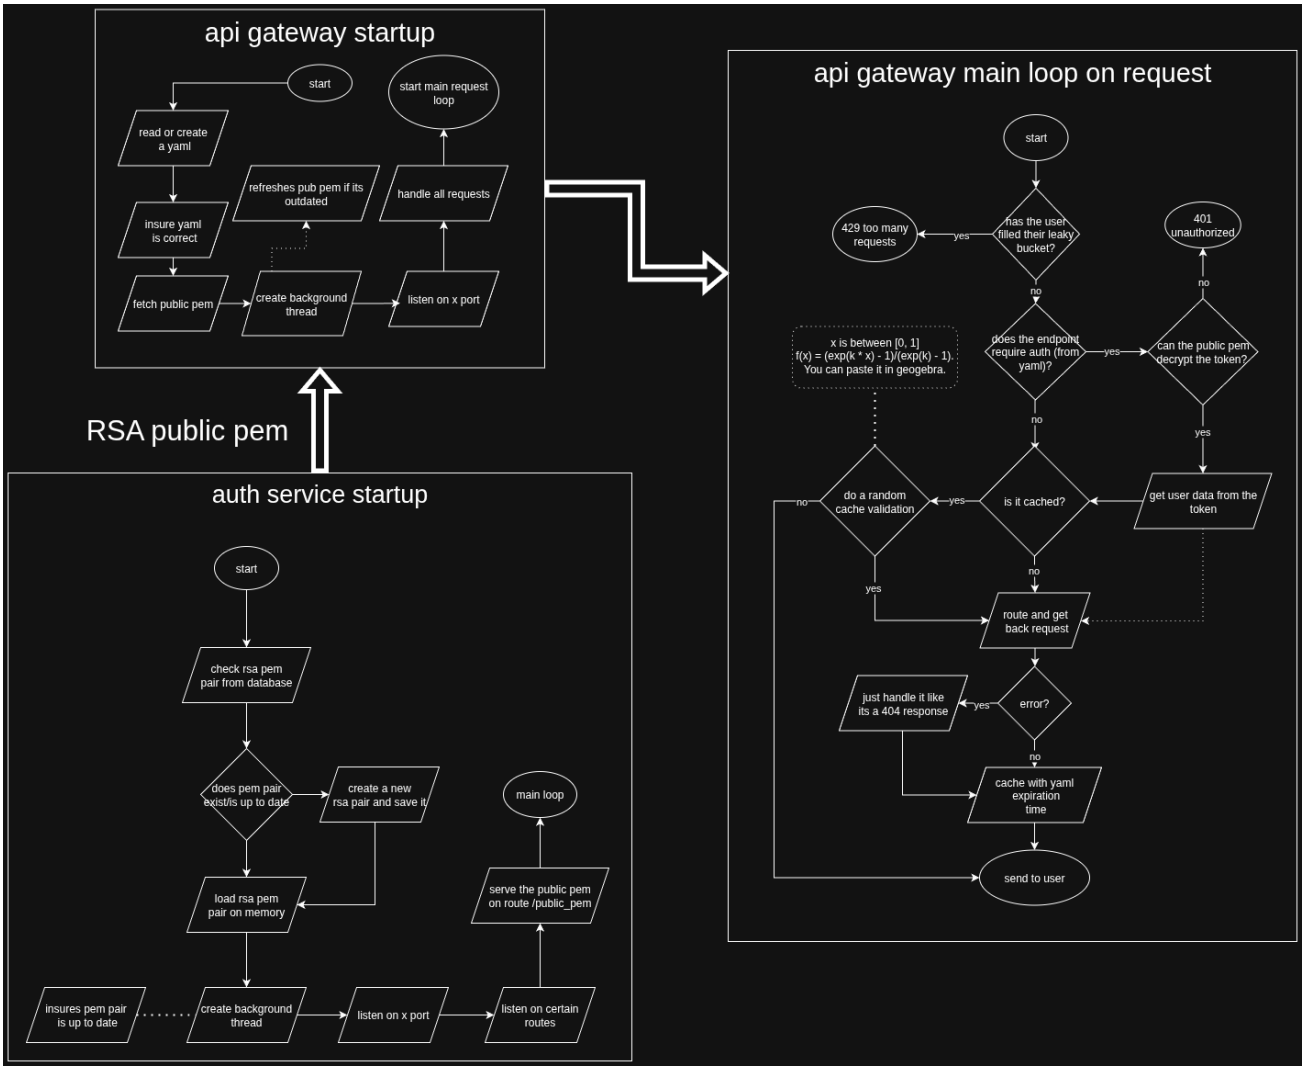

Фигура 4 Логическа схема на процеса на авторизация

Реализацията на системата се основава на високопроизводителна архитектура, която съчетава функционален и императивен стил на програмиране в езика Rust за постигане на

максимална предвидимост и сигурност на данните чрез централизирано управление на състоянието. Паралелизмът в приложението е обезпечен чрез използването на неблокиращи структури от данни и атомарни указатели с брояч на референциите, което предотвратява забавяния при четене и елиминира рисковете от надпревара на нишките. Комуникацията се осъществява чрез REST API интерфейс със JSON сериализация, придружен от автоматично генерирана документация чрез инструментите на Swagger за по-лесно интегриране и поддръжка. Сигурността е гарантирана от многослоен механизъм за автентикация и оторизация, базиран на JSON Web Tokens и дълготрайни рефреш токени, които позволяват автоматично подновяване на 15-минутни сесии без повторно въвеждане на парола. За криптографска защита на тези токени се прилага асиметричният алгоритъм RSA, при който частният ключ служи за подписване на достъпа, а публичният за неговата верификация, осигурявайки надеждна бариера пред нерегламентирани опити за достъп до административния интерфейс и критичните ресурси на системата. *(Фигура 4)*

Авторизацията се върши от 2 сервиса: auth и servo (api gateway).

- Auth service

Auth сервиса играе роля на енкапсулатор. Той отговаря за регенерирането на RSA ключовете и създаването на JWT. Това за Auth сервиса не отговаря е за верификацията на JWT. Auth сервиса има ендпоинт /public_pem, който връща RSA публичния ключ с целта всеки сервис да може да провери дали е валиден JWT.

- Servo

Servo взима публичния ключ от auth сервиса и с него проверява дали потребителят ползва валиден JWT.

4.5.10. Скрейпинг

Скрейпингът се изпълнява от 2 сервиса в екип: oxalate_outlet и oxalate_harvester.

- Oxalate_harvester

Той е оркестраторът на всички oxalate_outlet инстанции. Той генерира “задачи”, които се пращат на всички тях. Една задача се състои от списък с домейни, използвания от тях протокол, методи за протокола и хедъри. Инстанциите на oxalate_outlet връщат “решенията” на тези задачи, които представляват суровия HTML, върнат от всеки домейн. От този суров HTML

рекурсивно се извлича текстът от всички тагове, като се премахват ненужните (например <script>, <style>, <svg>). От суровия текст се премахват всички препинателни знаци и съюзи. Накрая информацията се обработва и изпраща към съответната база данни.

- Oxalate_outlet

Услугата приема “задачи” от oxalate_harvester. При получаване на заявка, тя започва асинхронно и паралелно изпълнение на заявки към всеки домейн в списъка, използвайки буфериране. След приключване на обработката, “решението” се връща към oxalate_harvester, след което се приема следващата задача.

Тъй като услугата не съхранява собствено състояние (stateless), тя зависи изцяло от входящите данни от oxalate_harvester. Това я прави изключително ефективна за хоризонтално мащабиране. Единственото ограничение за вертикално мащабиране на oxalate_outlet е лимитът на TCP сокетите на системното ядро (kernel). Ако лимитът се махне, ограничението става самото системно ядро.

4.5.11. Бази от от данни

За една търсачка е много важно как се запазва и структурира информация, за да връща резултати бързо. За тази цел са ползват 2 бази данни.

- ParadeDB (Postgres)

Това е модифицирана версия на postgres с векторни способности, пълнотекстово търсене и токенизатори. ParadeDB се използва за пълнотекстово търсене в голямата база от данни, като интегрира сложни търсещи алгоритми в Postgres. Основното предимство тук е използването на алгоритъма BM25, който служи за прецизно класиране (ranking) на резултатите според тяхната релевантност. BM25 оценява значението на ключовите думи спрямо общата дължина на текста и честотата на срещането им.

- Neo4J

За оптимизирана визуализация на връзките в резултатите от търсенето се използва графовата релационна база данни Neo4j. Процесът на изграждане на графа преминава през следните етапи: Приложението е разбито на четири основни групи компоненти, като някои от тях са разделени и на по-малки, за извършване на една конкретна функционалност.

1. Обработка на съдържанието: След като компонентът oxalate_harvester обработи страница с ключови думи, той прилага алгоритъм тип “плъзгащ се прозорец” (sliding window) върху извлечените термини.
2. Създаване на релации: За всяка комбинация от думи, попадащи в рамките на прозореца, се дефинира релация (връзка) в базата данни.
3. Изчисляване на тежестта: Ако дадена релация вече съществува, нейната “тежест” (weight) се инкрементира.
4. Визуализация: Финалните визуализации чрез граф се генерират динамично въз основа на изчислената тежест на релациите и общата честота на срещане на ключовите думи.

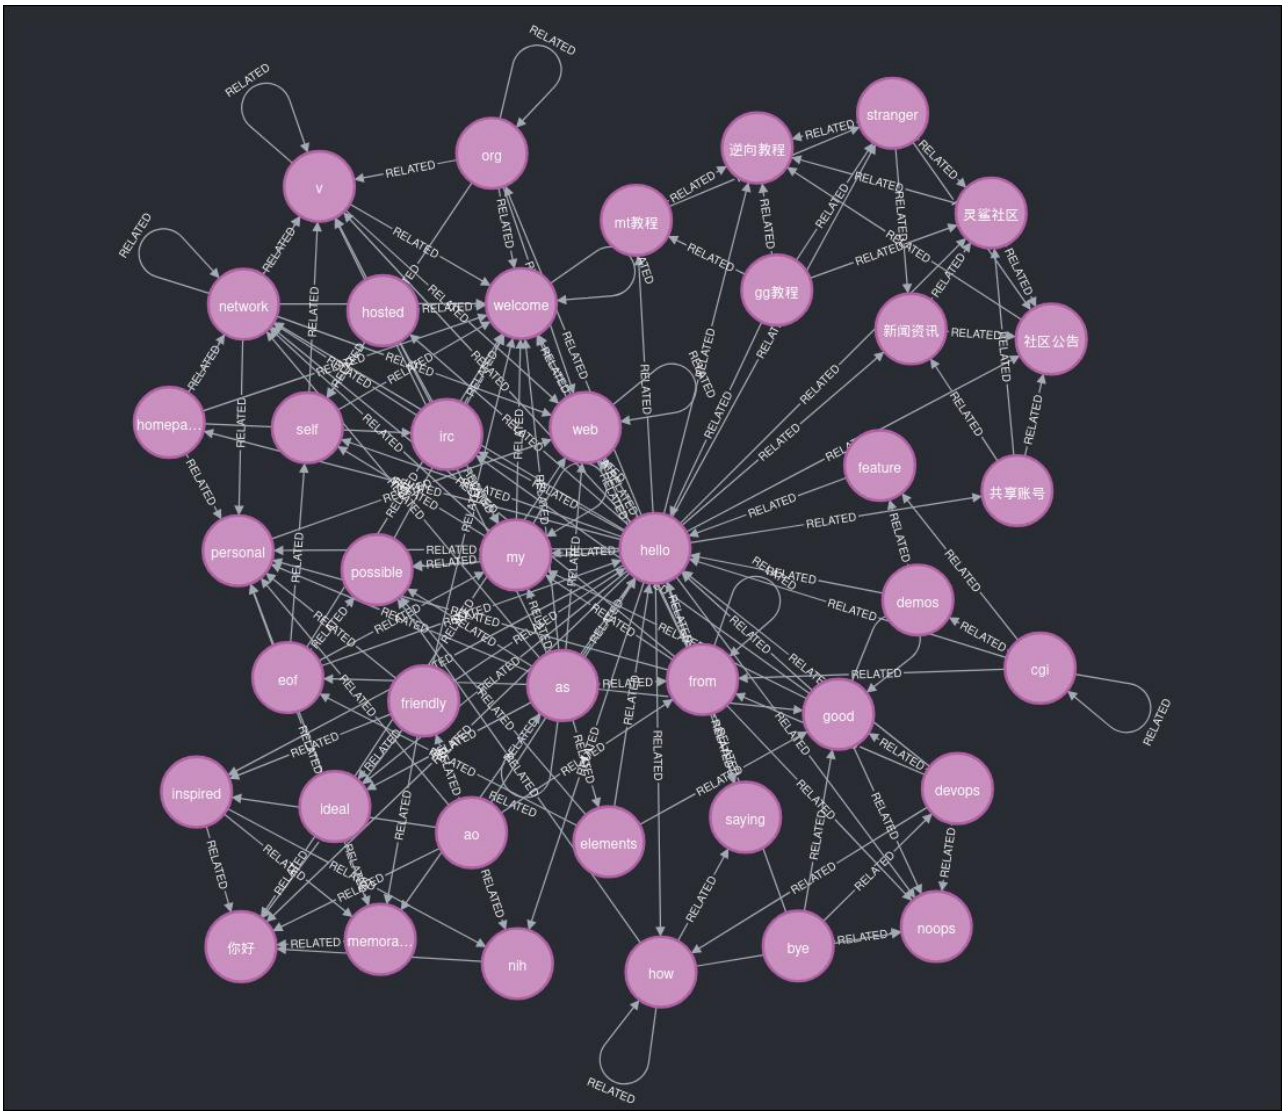

Фигура 5 Визуалиация на резултати от търсене

4.6.Описание на приложението

Цялата среда за разработка е автоматизирана с помощта на Nix и Docker Compose. Необходимо е да се следват тези стъпки, за да се подготви локалната машина:

- Стартиране на инфраструктурата

  Първо трябва да вдигнете необходимите услуги (бази данни и др.) чрез Docker. Отидете в директорията за деплоймънт и стартирайте контейнерите:

  cd deploy/dev

  docker-compose up –d

- Влизане в работната среда

  Вместо да инсталирате зависимости ръчно, използвайте Nix, за да влезете в изолирана среда с всички нужни инструменти:

  nix develop

- Изпълнение на миграции

  За да синхронизирате схемата на базата данни, използвайте sqlx-cli. Изпълнете миграциите за целия workspace:

  sqlx migrate run –workspace

https://oxalate.ate6.org/admin

Username: NOIT

Password: noit1234

4.7 Заключение

В резултат на извършеното проучване, проектиране и реализация беше създадена работеща интелигентна система за оптимизиране на търсенето в интернет, която обединява сигурност, висока производителност и иновативна визуализация на резултатите. Проектът успешно

реализира поставените цели, като предоставя както стандартно търсене на информация, така и интерактивно представяне на връзките между данните чрез графови структури.

Разработеното приложение е функционално и стабилно, като към момента може да бъде използвано от реални потребители чрез уеб интерфейс. Архитектурата на системата е проектирана модулно и мащабируемо, което позволява лесно разширяване и поддръжка на кода, както и добавяне на нови функционалности без съществени промени в съществуващата логика.

Съществуват редица възможности за бъдещо усъвършенстване на проекта. Сред тях са:

- внедряване на по-усъвършенствани алгоритми за семантично търсене и анализ на съдържанието;
- използване на машинно обучение за по-прецизно класиране и персонализиране на резултатите;
- оптимизация на графовите визуализации при работа с по-големи обеми от данни;
- разширяване на поддържаните източници за мета-търсене;
- добавяне на допълнителни административни инструменти за мониторинг и анализ на натоварването.

Проектът представлява солидна основа за бъдещо развитие и надграждане. Той демонстрира придобити знания и умения в областта на софтуерната архитектура, алгоритмите и разпределените системи и отговаря на изискванията за проект с висока сложност и практическа насоченост, характерни за Националната олимпиада по информационни технологии.

Източници

1. https://doc.rust-lang.org/stable/

2. https://www.typescriptlang.org/docs/handbook/typescript-in-5-minutes.html

3. https://nixos.org/

4. https://nuxt.com/docs/4.x/getting-started/introduction

5. https://docs.rs/axum/latest/axum/

6. https://docs.rs/utoipa/latest/utoipa/

7. https://swagger.io/

8. https://redis.io/

9. https://www.postgresql.org/docs/

10. https://neo4j.com/